

RTX 4050 Kapasite Raporu

Kademeli yük testi (4 → 8 → 12 → 16 kanal), gerçek TRT/DW yayınlarıyla, canlı ölçüm — tahmin içermez. 13 Ağustos 2026.

Özet

Sistem **8 kanalda tam stabil** (kuyruk yatay, drop yok, altyazı kapsamı %100), **12 kanalda kısmi bozulmaya** giriyor, **16 kanalda tamamen çöküyor** (11/16 kanalda altyazı hiç görünmüyor). Kırılmanın kök sebebi **GPU belleği (VRAM) değil** — tüm kademelerde VRAM kullanımı 6141 MB'lik kartın yarısının altında kaldı. Asıl sınır, yazılımdaki sabit eşzamanlılık ayarı (`STT_MAX_CONCURRENCY=6`) ve bunun üstüne 16 kanalda binen gerçek GPU doygunluğunun birleşimi.

Test Ortamı – Donanım

GPU	NVIDIA GeForce RTX 4050 Laptop, 6141 MB VRAM
Sürücü / CUDA	580.173.02 / CUDA 13.0
CPU	AMD Ryzen 7 7840HS, 16 iş parçacığı
RAM	30 GB
Not	Bu bir laptop/masaüstü kartı — Xorg (ekran) aynı GPU'yu paylaşıyor. Boşta GPU util'in %20-40 arası dalgalanması bundan; gerçek hesap yükü yok (güç çekimi düz 9W/80W).

Test Ortamı – Model ve Yazılım Ayarları

Konuşma tanıma (STT)

<code>STT_MODEL</code>	<code>small</code> (faster-whisper / CTranslate2)
<code>STT_DEVICE</code>	<code>cuda</code>
<code>STT_COMPUTE_TYPE</code>	<code>int8_float16</code>
<code>STT_BEAM_SIZE</code>	<code>1</code> (greedy — beam search değil)
<code>STT_BATCH_SIZE</code>	<code>16</code>
<code>STT_MAX_CONCURRENCY</code>	<code>6</code> — aynı anda en fazla 6 bölüt GPU'da işlenir
Görev (task)	<code>translate</code> — kaynak dil ne olursa olsun doğrudan İngilizce pivota çeviriyor

Çeviri (Marian / Opus-MT)

<code>STT_TARGET_LANGS</code>	<code>tr, de, ru</code> — İngilizce pivottan bu 3 dile
-------------------------------	--

Modeller	Helsinki-NLP/opus-mt-tc-big-en-tr, opus-mt-en-de, opus-mt-en-ru
Çalışma şekli	3 dil paralel (bu oturumda düzeltildi — önceden sıralıydı)

Ses bölütleme (VAD — Silero)

VAD_MODEL_VERSION	v5
VAD_MAX_SEGMENT_MS	4000 — bölüt en fazla 4 sn, sonra zorla kesilir
VAD_MIN_SILENCE_MS	400 — bu kadar sessizlik bölütü kapatır
VAD_OVERLAP_MS	800 — zorla kesimde bir sonraki bölütle örtüşme

Kuyruk / bütçe

Kanal başına kuyruk kapasitesi	4 (dolunca en eski düşer)
Gönderici thread sayısı (Java)	6 — Python'daki STT_MAX_CONCURRENCY ile aynı env, elle senkron tutulmuyor
ALTYAZI_BUTCE_MS	8000 — bir bölüt bunu aşarsa "kaçmış" sayılır

Metodoloji

Ölçüm protokolü (ölçekleme.md) — iki noktada uyarlandı:


- **Test kaynağı:** hazır dosya yerine **16 farklı gerçek TRT/DW kanalı** kullanıldı — gerçek, birbirinden tamamen farklı içerik.
- **Kuyruk/drop metriği:** bu oturumdan önce zaten Prometheus/Grafana'ya kurulmuştu.

Her kademedede: kanallar ayarlanır → **2 dakika ısınma** → **5 dakika gözlem** (GPU her saniye örneklenir, kuyruk/drop/gecikme/kapsama metrikleri başında ve sonunda okunur) → sonraki kademe.

Sonuçlar – Ana Tablo

KADEME	GPU (ORT)	VRAM (TEPE)	KUYRUK	DROP (5DK)	P50	P95	DURUM
4 kanal	%26,0	2643 MB	yatay	0	366–506 ms	745–6002 ms	akıyor %100
8 kanal	%41,3	3043 MB	yatay	0	339–774 ms	434–6308 ms	akıyor %100
12 kanal	%68,2	3075 MB	yatay*	0*	383–6212 ms	539–10146 ms	kesik %70–100
16 kanal	%83,7	3106 MB	tavanda (4/4)	~25–41/kanal	10406–16204 ms	14082–20492 ms	akmıyor, çoğu %0

* 12 kanalda kanal-başı kuyruk derinliği 0 gösterdi ama bu yanıltıcı olabilir — bkz. "Ölçüm sınırlaması" aşağıda. 10 drop oldu ama tamamı ısınma sırasında, gözlem penceresinde yeni drop = 0.



GPU kullanım oranı, kademe başına (ortalama %).

ÖLÇÜM SINIRLAMASI

`altyazi_kuyruk_derinlik` yalnızca kanal başına bekleyen bölüt sayısını ölçüyor. Bir bölüt bir gönderici thread'i tarafından alındığı an bu sayaçtan düşüyor — ama o thread hâlâ GPU'dan cevap bekliyor olabilir. 6 gönderici thread'in tümü doluya birikim **görünmez** bir şekilde ayrı bir kuyrukta oluyor (ölçülmedi). 12 kanalda derinliğin 0 görünmesine rağmen gecikmenin zaten yükselmiş olması (p95 10146ms) bunun kanıtı.

Kırılma Noktası

Sistemin stabil çalıştığı en yüksek kanal sayısı	8 kanal
Kırılmanın başladığı kanal sayısı	12 kanal
Sistemin tamamen çöktüğü kanal sayısı	16 kanal

Tek Segment İşleme Süresi (RTF)

İzole ölçüm — 0 aktif kanal, gerçek 6 saniyelik konuşma, 8 tekrar, **transkripsiyon + 3 dil çeviri birlikte** (tam çalışan hat):

Ortalama işlem süresi (6sn segment)

0,323 saniye

RTF (6,0 / işlem süresi)

18,59×

Doğruluk kontrolü — örnek çıktı: "and it is connected to the weight of the body or it is connected to the movement." → tr: "ve vücudun ağırlığına bağlıdır...", ru: "и он связан с весом тела...", de: "und es ist mit dem Gewicht..." — üçü de doğru üretildi.

Karşılaştırma: bu oturumdan önceki mimari (large-v3, beam=5, çeviri sıralı) ~1,3× birleşik RTF veriyordu — yeni mimari (small, beam=1, çeviri paralel) bunun ~14 katı.

Karışma Kontrolü

16 kanal aktifken 4 farklı kanalın (DW English, TRT Haber, TRT Spor, TRT Muzik) altyazı çıktısı veritabanından doğrudan karşılaştırıldı:

SONUÇ: KARIŞMA YOK

DW English → Al/savunma belgeseli (tutarlı) · TRT Haber → haber bülteni, "Aydın Tular, news" ile bitiyor (tutarlı) · TRT Spor → futbol sohbeti (tutarlı) · TRT Muzik → şarkı sözleri (tutarlı). 16 kanalda bile hiçbir kanalın çıktısında başka bir kanalın içeriği görülmedi.

Yorum – Hangi Senaryo?

Kademeye göre değişen, karma bir tablo:

12 kanalda (kırılmanın başladığı nokta): GPU util henüz %68,2 — doymamış, ama kapsama zaten düşüyor. Darboğaz `STT_MAX_CONCURRENCY=6` sabit tavanı — **yazılım sınırı**, donanım sınırı değil.

16 kanalda (tam çöküş): GPU util %83,7'ye çıkmış, gerçekten doymaya yaklaşıyor. Yani önce yazılım tavanı (6) vuruluyor, kanal sayısı büyüdükçe buna gerçek GPU doygunluğu da ekleniyor.

VRAM tüm kademelerde kesin olarak elendi: 4 → 16 kanal arası VRAM'de sadece ~460 MB fark (2643 → 3106 MB), her zaman 6141 MB'nin yarısının altında. Model ağırlıkları tek kopya paylaşıldığı ve eşzamanlılık sabit 6'da tavanlandığı için VRAM kanal sayısı ile orantılı büyümüyor.

A100'e Ekstrapolasyon

4050'de ölçülen stabil kanal sayısı	8
4050'de ölçülen RTF (tam hat)	18,59×
A100 avantaj çarpanı (kaba tahmin)	~5-8×
A100 tahmini stabil kanal	~40-64 kanal

VRAM'in 4050'de zaten %50'nin altında kalması, 8 kanallık sınırın VRAM'den değil

`STT_MAX_CONCURRENCY=6` tavanından geldiğini gösteriyor. A100'de (40 GB VRAM) bu tavan çok

daha ykseęe çekilebilir — yani tahmin sadece "daha hızlı GPU" deęil, "daha yksek concurrency ayarı" avantajına da dayanıyor; bu ikisi 5-8×'in stne çıkabilir ama bu da bir tahmindir.

ZORUNLU UYARI

Bu bir **TAHMİNDİR**. A100'n geręek kapasitesi ancak A100 zerinde aynı 4 kademeli test tekrarlanarak kesinleşir. 4050 → A100 ęarpanı GPU mimarisi farkları yznden doęrusal olmayabilir. "40-64 kanal A100'de geręekçi grnyor ama prod'da doęrulanmalı" — "64 kanal garanti" deęil.

Ek Bulgu – Test Sırasında Dzeltilen Bir Regresyon

İmaj yeniden kurulurken iki dıř/yan sorun çıktı, ikisi de test verisi toplanmadan nce dzeltildi:

- PyPI'da `nvidia-cudnn-cu12==9.1.0.70` kaldırılmıştı — torch 2.4-2.6/cu124 serisinin tamamı buna baęımlıydı, build'i kırıyordu. zm: CUDA indeksi `cu126`'ya ęevrildi.
- cu126'daki daha yeni torch, Marian ęevirisinde bir ęekirdeęi Triton (torch.compile alt katmanı) ile derlemeye ęalıřıyordu, container'da derleyici yoktu — ęeviri **%100 başarısız** oluyordu (fark edilmeseydi RTF lm geersiz olurdu). zm: `gcc`, `libc6-dev`, `python3-dev` eklendi.