

# Batching Katmanı — Canlı Ölçüm Sonuçları

15 kanal, STT\_MAX\_CONCURRENCY=6, kanallar arası batching aktif

13 Ağustos 2026 · 19:06–19:13 (2dk ısınma + 5dk gözlem) · RTX 4050 Laptop, 6141 MB VRAM

## ÖZET

Batching katmanı, aynı 15 kanalı **concurrency=20'nin tam çöküşünden** (kapsama tüm kanallarda %0) **kısmen sağlıklı bir duruma** (%14-%100 arası, çoğu kanal %40-67) taşıdı — donanım veya eşzamanlılık ayarı değişmeden. Ama **tam çözüm değil**: bazı kanallar hâlâ bütçeyi aşıyor, ve VRAM artık ilk kez gerçekten sınıra yaklaşıyor (%93,6 tepe).

## 1. Üç senaryonun karşılaştırması

|                           | Concurrency=6<br>(batching yok, referans) | Concurrency=20<br>(batching yok) | Concurrency=6<br>+ batching (bugün) |
|---------------------------|-------------------------------------------|----------------------------------|-------------------------------------|
| Kanal sayısı              | 8 (stabil nokta)                          | 15                               | 15                                  |
| Kuyruk derinliği          | 0 (yatay)                                 | 3-4 (tavanda)                    | 0 (tüm kanallarda)                  |
| Drop (5 dk, kanal başına) | 0                                         | 13-43                            | 0-6                                 |
| p50 gecikme               | 339-774 ms                                | 13-20 sn                         | 2,6-10 sn                           |
| p95 gecikme               | 434-6308 ms                               | 23-30 sn                         | 3,7-18,6 sn                         |
| Kapsama                   | %100 (hepsi)                              | %0 (hepsi)                       | %14-100 (karışık)                   |
| GPU util (ort.)           | %41,3                                     | %83,1                            | %55,6                               |
| GPU util (tepe)           | —                                         | %100                             | %100                                |
| VRAM (ort.)               | ~2900 MB                                  | 2984 MB                          | 4273 MB                             |
| VRAM (tepe)               | 3043 MB                                   | 3080 MB                          | 5746 MB (%93,6)                     |

## 2. Beklenmedik ve önemli bulgu: VRAM artık gerçekten dolmaya başladı

### İLK KEZ GÖRÜLÜYOR

Bu oturumdaki HİÇBİR testte (4/8/12/16 kanal, concurrency=6 veya 20) VRAM tepe kullanımı **3106 MB**'i geçmemişti — kartın yarısının altında. Batching devreye girince tepe **5746 MB**'a çıktı, kartın **%93,6**'sı.

**Neden:** Batching, N farklı kanalın ses özelliklerini **tek bir tensöre yığıyor** ( `numpy.stack` ) — 8 ögelik bir batch, aktivasyon belleğini (özellik matrisleri, ara hesaplamalar) yaklaşık 8 kat büyütüyor. Model ağırlıkları hâlâ tek kopya

ve sabit, ama **bir batch'in kendisi** artık gerçek VRAM tüketiyor — önceki mimaride (istekler ayrı ayrı, küçük küçük gidiyordu) hiç görülmeyen bir etki.

Bu, ilk defa VRAM'in gerçekten "iş yapan" bir kaynak haline geldiği an — daha önce hep boştaydı, artık batching sayesinde gerçekten kullanılıyor. İyi haber: kartın hâlâ ~%6'lık payı var. Kötü haber: bu pay, daha büyük bir batch boyutu ( `STT_BATCH_MAX_SIZE` ) denenirse hızla tükenebilir — bu ayar artık dikkatli ayarlanmalı.

### 3. Kapsama neden hâlâ %100 değil

| Kanal        | Kapsama | Kanal           | Kapsama |
|--------------|---------|-----------------|---------|
| TRT Müzik    | %100    | TRT Haber       | %57     |
| DW Espanol   | %100    | DW Arabia       | %57     |
| DW English   | %83     | TRT Kurdi       | %57     |
| TRT Arabi    | %67     | TRT Çocuk       | %50     |
| TRT 1        | %57     | Red Bull TV     | %40     |
| TRT Belgesel | %43     | TRT Spor Yıldız | %40     |
| TRT World    | %38     | TRT Avaz        | %29     |
| TRT Türk     | %14     |                 |         |

Kuyruk hiç dolmuyor (0), drop neredeyse yok (0-6/5dk) — yani bölütler kayıp gitmiyor, GPU'ya ulaşıyorlar. Ama bazıları **8 saniyelik bütçeyi** ( `ALTYAZI_BUTCE_MS` ) aşacak kadar geç geliyor (p95 15-18 sn) — bu yüzden kapsamaya "yetişmedi" olarak yansıyorlar. Sorun artık "kaybolma" değil, "gecikme" — kuyruk teorisi dilinde: sistem artık düşürmüyor ama **bekleme süresi (W)** hâlâ bütçenin üstünde bazı kanallar için.

### 4. Yorum — bu 15 kanal için "çözüldü" demek erken

#### DÜRÜST DEĞERLENDİRME

Batching, 15 kanalı **tamamen çöküşten** kurtardı ama **tam sağlıklı** hale getirmedi. 8 kanaldaki referans durumla (kapsama %100, drop 0, p95 <6,3sn) karşılaştırıldığında, 15 kanal hâlâ bu kartın gerçek kapasitesinin üzerinde — batching tavanı yükseltti, sonsuz yapmadı.

Ölçülmemiş olan: batching ile **yeni** stabil kanal sayısı kaç? Bu, eski kademeli testin (4 → 8 → 12 → 16) batching açıkken tekrarlanmasını gerektiriyor — bu rapor bunu yapmadı, sıradaki adım olmalı.

### 5. Önerilen sıradaki adımlar

- Yeni kademeli test:** Batching açıkken 8, 10, 12, 15 kanalı ayrı ayrı ölç — yeni "stabil" ve "kırılma" noktalarını bul.

2. **VRAM'i izle:** `STT_BATCH_MAX_SIZE` yükseltirise (daha büyük batch = daha fazla kazanç ama daha fazla VRAM) her denemede VRAM tepe değeri kaydedilmeli — artık gerçek bir sınır.
3. **Pencere süresini ayarla:** `STT_BATCH_WINDOW_MS=80` hiç ince ayar yapılmadan seçildi — daha uzun pencere (örn. 150-200ms) daha büyük batch'ler toplar, bütçeden (8000ms) hâlâ ihmal edilebilir bir pay.
4. **15 kanal gerçekten hedefse:** Mevcut kartta tam %100 kapsamaya ulaşmak için ya kanal sayısını (geçici olarak) düşürmek ya da batch parametrelerini bu ölçümle ince ayar yapmak gerekiyor.

---

Bu ölçüm, batching katmanının ilk canlı testidir. Önceki testlerle (concurrency=6/20, batching yok) aynı yöntemle (2dk ısınma + 5dk gözlem, aynı metrikler) karşılaştırılabilir şekilde yapıldı.